


# GENERATING BOTH REAL AND HARD NEGATIVES FOR RECOMMENDER SYSTEM

SIGMOD' 26 Round 2

February 25, 2026

## 1 Introduction



推荐系统本质上是在做 Embedding Learning，基于Pairwise Ranking损失(e.g. BPR Loss)训练的系统需要正例和负例来计算梯度，负采样决定了负例的选择。在这个任务当中，我们研究带有曝光数据(e.g. 被推荐了但是用户未交互的物品)情景下的负采样方法。

负采样面临着如下问题：

- **数据稀疏性：**在User-item Interaction Matrix当中，有许多未观测值。
- **难以利用曝光数据：**曝光数据往往也是稀疏的，不足以支撑训练，难以直接利用。
- **假负样本 False Negative Problem：**选择的负样本实际上是未交互的用户感兴趣的物品。

目前常见的负采样算法以及其优缺点如下：

- **Random Negative Sampling (RNS):**从未交互的样本中随机抽取作为负样本。
  - Pros: 快速。
  - Cons: 难以保证采样到的负样本是真实的负样本；无法保证负样本的难度，不利于训练；缺乏可解释性。
- **Hard Negative Sampling (HNS):**从未交互的样本中选择多个候选负样本，选择当前模型评分最高的候选负样本作为负样本。
  - Pros: 能够保证负样本的难度，给模型训练提供了足够的监督信号。
  - Cons: 难以保证采样到的负样本是真实的负样本，并且风险比RNS更高，因为模型打分高的样本也很有可能是正样本；候选池的大小可能带来计算效率的问题。
- **Popularity-biased Negative Sampling (PNS):**抽取流行的未交互物品作为负样本。
  - Pros: 一定的解释性。
  - Cons: 流行度偏差，不利于冷门物品。
- **Generative Negative Sampling:**生成负样本。
  - Pros: 学习了用户的负偏好分布，具有更好的解释性。
  - Cons: 现有方法缺少对曝光数据的利用。

## 2 Methodology

### 2.1 Problem Formulation

设用户集合为  $\mathcal{U}$ , 物品集合为  $\mathcal{I}$ , 曝光数据为  $\mathcal{E}$ . 我们的目标是学习一个条件生成模型  $G(\cdot | u)$ , 用于刻画用户  $u$  的**负偏好分布**.

对于给定用户  $u$ , 生成模型输出一组负样本  $I_u^-$ , 并用于训练推荐模型  $R$ . 与传统基于启发式规则的负采样方法不同, 我们显式建模“真实负样本”的分布, 再在此基础上引入难度约束.

### 2.2 Learning Negative Preference

在隐式反馈场景中, 未交互数据并不等价于负样本. 因此, 我们首先希望学习一个能够刻画“真实负样本”分布的生成模型.

具体而言, 我们采用 CondOT 路径下的条件 Flow Matching 方法, 学习从先验高斯噪声分布到用户负曝光集合  $\mathcal{E}_u^{neg}$  的映射.

其优化目标定义为:

$$\mathcal{L}_{CFM}(\theta) = E_{t, \mathbf{x}_0, u, \mathbf{e}_n} \left[ \|v_t^\theta(\mathbf{x}_t, u) - (\mathbf{e}_n - \mathbf{x}_0)\|^2 \right], \quad (1)$$

其中  $v_t^\theta$  表示时间相关的速度场,  $\mathbf{e}_n$  为真实负曝光样本.

通过最小化该损失, 我们学习一个条件传输映射, 使得噪声分布能够被映射到“真实负样本”分布上, 从而保证生成样本的真实性 (realness).

### 2.3 Adding Hardness to Negatives

学习真实负样本的分布保证了我们最后生成的负样本的真实性. 下面我们考虑负样本的难度, 也就是模型对它的打分. 对于一个真实的负样本, 如果它的分数很高, 那么说明模型难以区分它和正样本, 就说明这个负样本很有价值, 能够更好地提高模型的分辨能力. 从损失函数的角度分析, 假设正样本的打分已经很高, 那么难的负样本能够提供更大的梯度促进训练.  $\mathcal{L}_{BPR} = -\ln \sigma(\hat{r}_{ui} - \hat{r}_{uj})$ ,  $\frac{\partial \mathcal{L}_{BPR}}{\partial (\hat{r}_{ui} - \hat{r}_{uj})} = -(1 - \sigma(\hat{r}_{ui} - \hat{r}_{uj}))$ . 其中  $\hat{r}_{ui}, \hat{r}_{uj}$  分别是模型对正负样本的打分. 假设采用点积相似度, 要提高负样本的难度, 也就是要使得最后生成的负样本在 latent space 中尽可能靠近它对应的 user embedding  $u$ . 从概率的角度看, 我们要做的实际上是找到分布当中尽可能靠近 user embedding 的点.

$$v_t^\theta(\mathbf{x}_t, u) = A \nabla \log p_t(x_t | u) + B, \quad A = \frac{1}{t}(t-1), B = \frac{1}{t}x_t, p_t(\cdot | u) \sim \mathcal{N}(tu, (1-t)^2 I). \quad (2)$$

$$\nabla \log p_t(x_t | u) = \underbrace{\nabla \log p_t(x_t)}_{\text{UnconditionalScore}} + \underbrace{\nabla \log p_t(u | x_t)}_{\text{GuidanceScore}}.$$

Flow Matching 实际上是学习了一个双射函数, 我们可以在初始的噪声分布上找到被映射到靠近 user 的分布边缘上的点.

$$\mathbf{x}_1 = \mathbf{x}_0 + \int_0^1 v_t(\mathbf{x}_t) dt \approx \mathbf{x}_0 + v_0^\theta(\mathbf{x}_0, u). \quad (3)$$

为了增加负样本难度, 我们在生成前对初始噪声进行梯度引导:

$$\begin{aligned} \mathbf{x}_0 &\sim \mathcal{N}(0, I), \\ \mathbf{g} &= \nabla_{\mathbf{x}_0} ((\mathbf{x}_0 + v_0^\theta(\mathbf{x}_0, u))^\top u), \\ \mathbf{x}_0' &= \mathbf{x}_0 + \alpha \mathbf{g}. \end{aligned}$$

更新后的  $\mathbf{x}_0'$  作为新的初始点进行生成, 从而得到更加接近用户表示、难度更高的负样本.

### 2.4 Sampling

生成模型输出的是连续表示  $\mathbf{x}_1 \in R^d$ , 但推荐系统训练需要离散物品索引  $j \in \mathcal{I}$ .

为此, 我们将生成向量与物品嵌入空间进行匹配. 具体而言, 对于每个物品嵌入  $\mathbf{e}_j$ , 计算相似度:

$$s_j = \mathbf{x}_1^\top \mathbf{e}_j. \quad (4)$$

随后通过 softmax 归一化得到条件分布:

$$p(j | \mathbf{x}_1) = \frac{\exp(s_j/\tau)}{\sum_{k \in \mathcal{I}} \exp(s_k/\tau)}, \quad (5)$$

其中  $\tau$  为温度参数.

最终, 我们根据该分布进行采样或选择 top- $k$  物品, 作为生成的离散负样本.




Figure 1: 先估计当前从当前噪声出发生成的样本，然后通过打分函数的梯度先更新初始噪声，然后生成.

## 2.5 Training

### 2.5.1 Hardness Scheduling

直接生成极难负样本可能导致训练不稳定，尤其是在推荐模型尚未充分收敛的早期阶段.

因此，我们引入 hardness scheduling 机制，逐步增强负样本的难度.

我们采用逐步增加的引导强度  $\alpha_t$ :

$$\alpha_t = \alpha_{\max} \cdot \frac{t}{T}, \quad (6)$$

或等价地，通过逐步降低 softmax 温度  $\tau_t$ ，使生成分布在训练后期更加集中于高相似度区域. 该机制本质上是一种 curriculum learning，使模型从容易区分的负样本过渡到困难负样本.